总体数据上传规范

教师端 · 2026-09-07

一、先明确总体和分析单位

> 上传表被视为本实验的完整虚拟总体：每一行是一个分析单位，行数就是总体规模 N。请明确研究问题、目标人群或对象以及时间范围。不能把预先抽出的子样本默认为原总体，否则总体真值、抽样比和有限总体修正都会改变。

系统当前支持一个主要目标：数值均值，或某个明确类别的单位比例。它不自动处理总量、回归、因果效应或纵向重复测量。

二、文件规则

- 支持 .xlsx、.xls、.csv；有效数据 1–100,000 行、2–50 列。
- 第一行是表头，名称不能为空或重复；不能使用系统保留前缀 __wj_。
- 不允许完全空白的数据行。CSV 应正确处理编码、引号、逗号和换行。
- 若超过行数上限，请明确重建一个较小的教学总体，并同步修改研究总体定义。不能通过先抽样、再把样本当完整总体来声称保留原调查设计。

三、根据目标和方法选择字段

- **标识符：必须 1 个。**每个总体单位的标识应非空且唯一。
- **均值目标：**选择数值字段作为目标；目标允许负值或零均值，但当前规划要求正且有限的总体方差。单位、评分尺度和均值含义需能解释。
- **比例目标：**选择分类字段和明确的目标类别。可以没有数值变量；不要为了上传而添加没有统计意义的数值编码。

- **分层变量：**仅当启用分层抽样时需要，须完整且有 2–20 个类别。没有合适分层变量时，将分层抽样设为不适用。每个非空层至少抽取 1 个单位；分层为必做时，最终样本量需足以覆盖一种可用分层方案。
- **PPS 辅助规模变量：**执行 PPS 时须使用抽样前已知的数值字段，每个单位均为有限正数，且不能与明确的研究目标变量相同。没有合适规模变量时将 PPS 设为不适用。规模越大不意味着对所有研究指标都更高效。
- **其他分类变量：**可用于比例目标和分布对照。字段角色不能重复分配，数值字段不能含空值或非法数值；分层字段不能含空值。

简单随机抽样必须完成，模板至少启用两种抽样方法。纯分类课题可启用简单随机和系统抽样，并按数据情况启用分层；不要求为了 PPS 而虚构规模变量。

四、准备示例

- 产品缺陷比例：产品编号、是否缺陷；目标为“是否缺陷=是”，可不配置数值变量。
- 企业平均利润：企业编号、利润、行业；利润是均值目标，行业可用于分层，利润可正可负。
- 住户消费均值：住户编号、消费金额、家庭人数、地区；以消费为目标，可评估用事先已知的家庭人数进行 PPS。

五、上传前核对

- 表中行与研究中的分析单位一一对应，重复时点不是独立对象的替代。
- 研究问题、总体定义、时间范围、字段含义和计量单位一致。
- 字段完整、标识唯一、没有空白行，类别数量符合启用方法的要求。
- 使用合成或适当处理的教学数据；不收集与教学目的无关的身份信息。